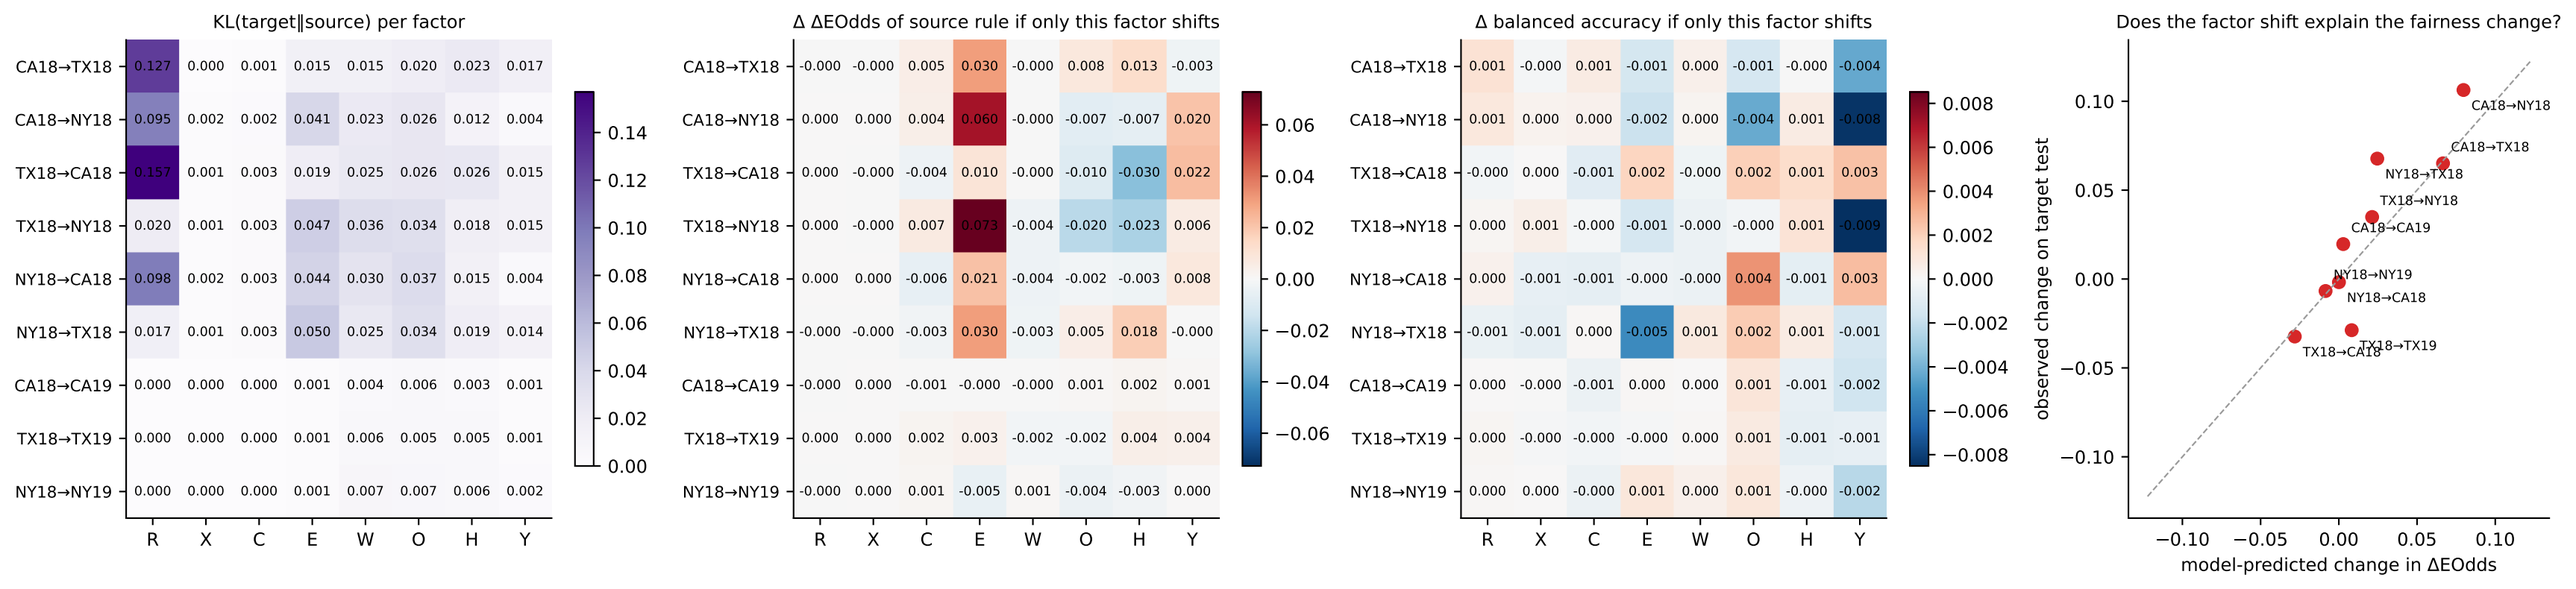
KL(target‖source) per factor
CA18→TX18 0.127 0.000 0.001 0.015 0.015 0.020 0.023 0.017
CA18→NY18 0.095 0.002 0.002 0.041 0.023 0.026 0.012 0.004
TX18→CA18 0.157 0.001 0.003 0.019 0.025 0.026 0.026 0.015
TX18→NY18 0.020 0.001 0.003 0.047 0.036 0.034 0.018 0.015
NY18→CA18 0.098 0.002 0.003 0.044 0.030 0.037 0.015 0.004
NY18→TX18 0.017 0.001 0.003 0.050 0.025 0.034 0.019 0.014
CA18→CA19 0.000 0.000 0.000 0.001 0.004 0.006 0.003 0.001
TX18→TX19 0.000 0.000 0.000 0.001 0.006 0.005 0.005 0.001
NY18→NY19 0.000 0.000 0.000 0.001 0.007 0.007 0.006 0.002
R X C E W O H Y
0.14 0.12 0.10 0.08 0.06 0.04 0.02 0.00
Δ ΔEOdds of source rule if only this factor shifts
CA18→TX18 -0.000 -0.000 0.005 0.030 -0.000 0.008 0.013 -0.003
CA18→NY18 0.000 0.000 0.004 0.060 -0.000 -0.007 -0.007 0.020
TX18→CA18 0.000 -0.000 -0.004 0.010 -0.000 -0.010 -0.030 0.022
TX18→NY18 0.000 -0.000 0.007 0.073 -0.004 -0.020 -0.023 0.006
NY18→CA18 0.000 0.000 -0.006 0.021 -0.004 -0.002 -0.003 0.008
NY18→TX18 -0.000 -0.000 -0.003 0.030 -0.003 0.005 0.018 -0.000
CA18→CA19 -0.000 0.000 -0.001 -0.000 -0.000 0.001 0.002 0.001
TX18→TX19 0.000 0.000 0.002 0.003 -0.002 -0.002 0.004 0.004
NY18→NY19 -0.000 0.000 0.001 -0.005 0.001 -0.004 -0.003 0.000
R X C E W O H Y
0.06 0.04 0.02 0.00 −0.02 −0.04 −0.06
Δ balanced accuracy if only this factor shifts
CA18→TX18 0.001 -0.000 0.001 -0.001 0.000 -0.001 -0.000 -0.004
CA18→NY18 0.001 0.000 0.000 -0.002 0.000 -0.004 0.001 -0.008
TX18→CA18 -0.000 0.000 -0.001 0.002 -0.000 0.002 0.001 0.003
TX18→NY18 0.000 0.001 -0.000 -0.001 -0.000 -0.000 0.001 -0.009
NY18→CA18 0.000 -0.001 -0.001 -0.000 -0.000 0.004 -0.001 0.003
NY18→TX18 -0.001 -0.001 0.000 -0.005 0.001 0.002 0.001 -0.001
CA18→CA19 0.000 -0.000 -0.001 0.000 0.000 0.001 -0.001 -0.002
TX18→TX19 0.000 -0.000 -0.000 -0.000 0.000 0.001 -0.001 -0.001
NY18→NY19 0.000 0.000 -0.000 0.001 0.000 0.001 -0.000 -0.002
R X C E W O H Y
0.008 0.006 0.004 0.002 0.000 −0.002 −0.004 −0.006 −0.008
Does the factor shift explain the fairness change?
observed change on target test
model-predicted change in ΔEOdds
0.10 0.05 0.00 −0.05 −0.10
−0.10 −0.05 0.00 0.05 0.10
CA18→NY18
CA18→TX18
NY18→TX18
TX18→NY18
CA18→CA19
NY18→NY19
NY18→CA18
TX18→TX19
TX18→CA18